

Lab 2 Revision: The A/B Test, Injaz and Sofra

Experimentation, A/B Testing and Causal Inference (SDA-DSC-213), SDAIA Academy. Revision sheet for participants.

1. The Injaz case حالة إنجاز

After Day 1 showed that the logs overstated the guided uploader, Injaz ran a proper experiment: 80,000 eligible users assigned by a hash of their user ID, half to the old uploader (control), half to the guided one (treatment). Lab 2 followed the full path of a real experiment: plan the sample size, verify the assignment, estimate the lift, check the guardrails, look at segments carefully, and decide when to stop looking.

بعد أن بيّن اليوم الأول أن السجلات بالغت في أثر الرفع الموجّه، أجرت إنجاز تجربة سليمة: 80,000 مستخدم مؤهل وُزّعوا بتجزئة معرّف المستخدم، نصفهم للرافع القديم (الضابطة) ونصفهم للموجّه (المعالجة). سار المعمل الثاني على المسار الكامل لتجربة حقيقية: تخطيط حجم العينة، والتحقق من التوزيع، وتقدير الرفع، وفحص مقاييس الحماية، والنظر في الشرائح بحدز، وتقرير متى نتوقف عن النظر.

2. The words المصطلحات

Word	What it is	ما هو
MDE	Minimum detectable effect, the smallest lift worth detecting: +0.02 here. A business decision.	الحد الأدنى للأثر القابل للاكتشاف، أصغر رفع يستحق الاكتشاف: +0.02 هنا. قرار تجاري.
α, power	$\alpha = 0.05$: the false-alarm rate we accept. Power = 0.80: the chance of catching a real MDE-sized effect.	$\alpha = 0.05$: معدل الإنذار الكاذب المقبول. القوة = 0.80: احتمال اكتشاف أثر حقيقي بحجم MDE.
n per arm	Users needed in each arm: 9,666. Halving the MDE multiplies n by four.	المستخدمون اللازمون في كل ذراع: 9,666. تنصيف MDE يضاعف n أربع مرات.
Hash assignment	Arm = deterministic function of user ID and a salt. Auditable; anyone can recompute it.	الذراع = دالة حتمية لمعرّف المستخدم وملح. قابل للتدقيق؛ يستطيع أي شخص إعادة حسابه.
SRM	Sample ratio mismatch: arm sizes differ from the design. Means the data are invalid, not that the effect is small.	عدم تطابق نسبة العينة: حجما الذراعين يختلفان عن التصميم. يعني أن البيانات غير صالحة، لا أن الأثر صغير.
Balance, SMD	Standardized mean difference of a covariate between arms; below 0.1 is balanced.	الفرق المعياري للمتوسطات لمتغير مصاحب بين الذراعين؛ دون 0.1 متوازن.
A/A test	Two arms, same product; any effect is a pipeline bug. Over many repeats it must flag about 5 percent.	ذراعان بالمنتج نفسه؛ أي أثر خلل في المسار. عبر تكرارات كثيرة يجب أن يُعلم نحو 5 بالمئة.
CUPED	Subtract from Y the part predicted by a pre-experiment covariate. Same lift, smaller SE. Only pre-treatment variables qualify.	اطرح من Y الجزء الذي يتنبأ به متغير مصاحب سابق للتجربة. الرفع نفسه وخطأ معياري أصغر. المتغيرات السابقة للمعالجة وحدها مؤهلة.

Guardrail	A metric that must not get worse. Tested as a family with Bonferroni (α divided by the number of guardrails).	مقياس يجب ألا يسوء. يُختبر كعائلة بونفيروني (α مقسومة على عدد مقاييس الحماية).
FWER vs FDR	Bonferroni almost never allows one false alarm (guardrails). Benjamini-Hochberg allows a controlled share of false alarms among the winners (exploratory segments).	بونفيروني يكاد لا يسمح بإنذار كاذب واحد (مقاييس الحماية). بنجاميني-هوكبرغ يسمح بنسبة مضبوطة من الإنذارات الكاذبة بين الفائزين (الشرائح الاستكشافية).
Peeking, mSPRT	Peeking: stopping at the first p below 0.05 after repeated looks; inflates false alarms. mSPRT: an always-valid boundary you may check at every look.	الاطلاع المبكر: التوقف عند أول p دون 0.05 بعد نظرات متكررة؛ يضخم الإنذارات الكاذبة. mSPRT: حد صالح دائماً يمكن فحصه في كل نظرة.

3. The numbers الأرقام

Quantity	Value	Reading	القراءة
n per arm for MDE 0.02; run length	9,666; 14 days	Two methods agreed; the 14-day floor covers weekly cycles.	اتفقت طريقتان؛ الحد الأدنى 14 يوماً يغطي الدورات الأسبوعية.
Assignment reproduced; SRM p	100 percent; 0.31	Nobody moved users between arms; sizes fit 50/50.	لم ينقل أحد المستخدمين بين الذراعين؛ الحجمان يناسبان 50/50.
SRM after dropping 3 percent of treatment	$p = 1e-7$	A small leak is caught instantly. Stop and investigate.	تسرب صغير يُكتشف فوراً. توقف وحقّق.
A/A false-positive rate, 500 runs	4.8 percent	The pipeline is calibrated.	المسار معاير.
Lift	+0.0223, SE 0.0035	Treatment completes 2.2 points more; truth 0.02.	المعالجة تُتم بزيادة 2.2 نقطة؛ الحقيقة 0.02.
95 percent CI	[0.015, 0.029]	Clears zero, centred on the MDE.	تتجاوز الصفر ومتمركزة حول MDE.
CUPED	SE 0.0033, variance -13 percent	Same lift; next test needs 13 percent fewer users.	الرفع نفسه؛ الاختبار التالي يحتاج مستخدمين أقل بنسبة 13 بالمئة.
Guardrails after Bonferroni	all OK	Time, tickets, upload errors: none regressed.	الزمن والتذاكر وأخطاء الرفع: لم يتراجع أي منها.
Segments: raw significant / survive BH, of 31	6 / 1	Five of six wins were noise; one becomes a hypothesis for the next test.	خمسة من ستة انتصارات ضجيج؛ واحد يصبح فرضية للاختبار التالي.
Peeking false-positive rate, 1 / 5 / 10 / 20 looks	4.7 / 13.4 / 19.6 / 25.5 percent	Twenty looks turn a 5 percent test into a 25 percent test.	عشرون نظرة تحوّل اختبار 5 بالمئة إلى 25 بالمئة.

mSPRT, 20 looks: no effect / real effect	1.4 percent / full power	Look as often as you like; still valid.	انظر كما تشاء؛ يبقى صالحاً.
--	--------------------------	---	-----------------------------

4. Statistics in five lines الإحصاء في خمسة أسطر

Sample size: $n \text{ per arm} = (z_{\alpha/2} + z_{\beta})^2 \times 2p(1-p) / \text{MDE}^2 = 2.80^2 \times 2 \times 0.2475 / 0.0004 \approx 9,700$. **Chi-square for SRM:** sum of $(\text{observed} - \text{expected})^2 / \text{expected}$ over the arms. **Robust SE (HC3):** does not assume equal variance in both arms; matches Neyman. **CUPED:** $Y_{\text{adj}} = Y - \theta(X_{\text{pre}} - \text{mean } X_{\text{pre}})$, $\theta = \text{cov}(Y, X_{\text{pre}}) / \text{var}(X_{\text{pre}})$. **Bonferroni vs BH:** Bonferroni compares each p with α/m ; BH sorts the p -values and compares the k -th smallest with $k\alpha/m$.

حجم العينة: n لكل ذراع $\approx (z_{\alpha/2} + z_{\beta})^2 \times 2p(1-p) / \text{MDE}^2 = 2.80^2 \times 2 \times 0.2475 / 0.0004 \approx 9,700$

9,700. مربع كاي لعدم تطابق النسبة: مجموع (المرصود - المتوقع)²/المتوقع على الذراعين. الخطأ المعياري المتين (HC3): لا يفترض تساوي التباين في الذراعين؛ يطابق نيمان. **CUPED:** $Y_{\text{adj}} = Y - \theta(X_{\text{pre}} - \text{متوسط } X_{\text{pre}})$, $\theta = \text{cov}(Y, X_{\text{pre}}) / \text{var}(X_{\text{pre}})$. **BH** مقابل **BH**: بونفيروني يقارن كل p بـ α/m ؛ و BH يرتب القيم p ويقارن الأصغر رقم k بـ $k\alpha/m$.

5. A second case to practise on: Sofra حالة ثانية للتدريب: سفرة

Sofra now runs a randomized test of **express checkout**: every customer reaching checkout is hashed into control or treatment, 50/50, for three weeks. Baseline completion is 0.58 and the team agreed an MDE of 3 points. Guardrails: refund rate, wrong-address rate, time to pay. Pre-experiment covariate: each customer's completion rate in the previous month.

تجري سفرة الآن اختباراً عشوائياً للدفع السريع: كل عميل يصل إلى الدفع يُجزأ إلى ضابطة أو معالجة، 50/50، لثلاثة أسابيع. الإتمام الأساسي 0.58 واتفق الفريق على حد أدنى للأثر 3 نقاط. مقاييس الحماية: معدل الاسترداد، ومعدل العنوان الخاطئ، وزمن الدفع. المتغير المصاحب السابق للتجربة: معدل إكمال كل عميل في الشهر السابق.

Quantity	Value	Reading	القراءة
n per arm for MDE 0.03 at $p = 0.58$	about 4,250	$2.80^2 \times 2 \times 0.2436 / 0.0009$. Sofra has 60,000 checkouts a week, so days, not weeks; keep 14 days for weekly cycles.	$2.80^2 \times 2 \times 0.2436 / 0.0009$. لدى سفرة 60,000 دفع أسبوعياً، فأيام لا أسابيع؛ أبقِ 14 يوماً للدورات الأسبوعية.
SRM	48,900 vs 51,100, p below 0.001	Illustrative failure: the iOS build shipped the feature a day late. Stop; the data before the fix are invalid.	فشل توضيحي: إصدار iOS أطلق الميزة متأخراً يوماً. توقف؛ البيانات قبل الإصلاح غير صالحة.
Lift after the fix (CUPED)	+0.041, CI [0.029, 0.053]	Real and above the 3-point MDE.	حقيقي وفوق حد الأدنى 3 نقاط.
Guardrail wrong-address rate	+0.006, Bonferroni p	A regression: saved addresses are	تراجع: العناوين المحفوظة قديمة أحياناً. تعليق حتى

	= 0.03	sometimes stale. HOLD until fixed.	الإصلاح.
Segments, 24 city × platform cells	4 row, 0 after BH	No segment story; do not build a city-specific rollout on it.	لا قصة شرائح؛ لا تبني إطلاقاً خاصاً بمدينة عليها.

The Sofra numbers are illustrative, chosen to mirror the Injaz lab; they do not come from a notebook.

6. Self-check اختبار نفسك

1. Sofra wants the MDE at 1.5 points instead of 3. What happens to n per arm? 2. Could time to pay be the CUPED covariate? 3. The lift clears the MDE but a guardrail regressed. Ship?

1. تريد سفرة MDE بمقدار 1.5 نقطة بدلاً من 3. ماذا يحدث لـ n لكل ذراع؟ 2. هل يمكن أن يكون زمن الدفع متغير CUPED المصاحب؟ 3. تجاوز الرفع MDE لكن مقياس حماية تراجع. هل نطلق؟

Answers. 1. Four times larger, about 17,000. 2. No; it is measured during the test and can be affected by the treatment; only pre-period variables qualify. 3. No; one guardrail regression holds the launch regardless of the lift; fix and re-test.

الإجابات. 1. أربعة أضعاف، نحو 17,000. 2. لا؛ يُقاس أثناء الاختبار ويمكن أن تؤثر فيه المعالجة؛ المتغيرات السابقة للتجربة وحدها مؤهلة. 3. لا؛ تراجع مقياس حماية واحد يعلّق الإطلاق مهما كان الرفع؛ أصلح وأعد الاختبار.